

占位符


大模型RAG技术 快速入门介绍

九天Hector

大模型挂载知识库核心技术：RAG

Retrieval Augmentation Generation

- RAG技术也被称作**知识检索增强技术**，旨在为大模型灵活的提供外部知识库支持，以拓展大模型知识边界；
- 对于大模型来说，知识直接代表其功能水平，合理的挂载外部知识库，不仅能进行**更大范围选题的问答**，同时也有助于大模型构建**Agent能力增强**...



RAG技术诞生的原因

大模型最大对话上下文限制

- 尽管大模型的训练数据看似可以无限增加，但在执行每一次对话任务的时候，受到算法原理限制，大模型可以处理的文本长度是有限的；
- 此外，由于单次训练的成本高昂、训练文本具有时效性以及少量信息文本无法被模型学习，这就导致大模型本身对于专业性知识和实效性较强的知识响应能力很弱。

GPT-4o

GPT-4o (“o” for “omni”) is our most advanced GPT model. It is multimodal (accepting text or image inputs and outputting text), and it has the same high intelligence as GPT-4 Turbo but is much more efficient—it generates text 2x faster and is 50% cheaper. Additionally, GPT-4o has the best vision and performance across non-English languages of any of our models. GPT-4o is available in the OpenAI API to paying customers. Learn how to use GPT-4o in our [text generation guide](#).

MODEL	DESCRIPTION	CONTEXT WINDOW	MAX OUTPUT TOKENS	TRAINING DATA
gpt-4o	GPT-4o: Our high-intelligence flagship model for complex, multi-step tasks. GPT-4o is cheaper and faster than GPT-4 Turbo. Currently points to gpt-4o-2024-08-06.	128,000 tokens	16,384 tokens	Up to Oct 2023
gpt-4o-2024-08-06	Latest snapshot that supports Structured Outputs . gpt-4o currently points to this version.	128,000 tokens	16,384 tokens	Up to Oct 2023
gpt-4o-2024-05-13	Original gpt-4o snapshot from May 13, 2024.	128,000 tokens	4,096 tokens	Up to Oct 2023
chatgpt-4o-latest	Dynamic model continuously updated to the current version of GPT-4o in ChatGPT. Intended for research and evaluation [1] .	128,000 tokens	16,384 tokens	Up to Oct 2023

占位符

为大模型的每次响应合理的**增加基础背景知识**
就成了当代大模型技术应用的**核心技术之一**

更新大模型知识库设计

思路一：知识灌注

- 借助**模型训练进行知识灌注**：在模型预训练、全量指令微调、或者高校微调阶段输入特定领域文本，从而让模型“**永久的记住**”某些信息；
- 问题一，效果不稳定：**若只带入少量专业文本，模型无法表现出智能**，若带入海量互联网文本，少量专业文本就会被“淹没”；
- 问题二，成本高昂：每次训练都需要耗费大量的成本时间，且效果不稳定；

更新大模型知识库设计

思路二：增加模型上下文长度

- 增加模型上下文长度，从而每次问答的时候都把相关的文档一次性全部输入：典型代表**GLM4-long**，最多可以；
- 此外，近一段时间由Claude开创的提示词缓存技术，也是变相增加了模型上下文长度；
- 问题在于，**受限于大模型本身原理，模型上下文无法无限拓展**，且每次输入大量文本也会导致算力消耗大幅增加；




更新大模型知识库设计

思路三：知识检索

- **RAG知识检索**：希望能找到一种方法，每次大模型回复之前，都可以把问题相关的文本内容输入给大模型，这样一来既节省了成本、同时又能提高模型响应速度，且具备极强的可拓展性；
- 问题在于，**如何把问题相关的文档片段“检索出来”**。

通用RAG基础流程



- Step 1.按照某种方式，**将长文档切分为一个个短文档**；
- Step 2.将用户的问题和短文档进行匹配，**找到最相关的topk个短文档**；
- Step 3.**将短文档作为系统消息输入给模型**，并引导模型回答用户原始问题；

占位符

RAG技术核心步骤与通用优化方法

占位符

文档切分



文档匹配与输入



模型问答



- 根据关键字符切分或根据字符串长度切分、以及滑动窗口切分等；
- 围绕不同类型文本，可选不同切分策略；
- 文本数据清洗占绝大多数时间，也是本环节提效的关键；
- 根据Embedding进行文本词向量化处理，并根据余弦相似度判断和问题相关的文档；
- 选择更好的Embedding模型、以及匹配后文本增强、重拍等，是优化的关键；
- 灵活判断文档段落内容是否可用、并根据文档进行回答；
- 真实性检验、后处理、用户意图判断是本环节优化的关键；

占位符

快速发展的RAG技术体系

新一代实体关系挖掘RAG系统

GraphRAG




<https://github.com/search?q=graphRAG&type=repositories>


快速发展的RAG技术体系

基于o1大模型的DRAG与IterDRAG

Inference Scaling for Long-Context Retrieval Augmented Generation



Inference Scaling for Long-Context Retrieval Augmented Generation



RAG实践落地策略

- 手动搭建RAG引擎；
- 使用LangChain、Llama-index等开源项目快速搭建；
- 使用GLM、OpenAI Assistant API等进行快速实现；

占位符

RAG基本概念与实现方法



RAG核心库与热门项目介绍



- Level 2 -

大模型进阶技术概览

Part 3.大模型RAG技术概览-1

>> 扫码添加**助理英英**
>> 回复**地图**领取高清原图



占位符

RAG项目评估与优化



本地知识库RAG技术实战



- Level 2 -

大模型进阶技术概览

Part 3.大模型RAG技术概览-2



>> 扫码添加**助理英英**

>> 回复**地图**领取高清原图

占位符

即将进入RAG手动实践实操教程...