

DeepSeek R1本地知识库问答

快速实战流程

一、主流大模型Web对话框架介绍

本节公开课，我们来详细介绍如何借助DeepSeek R1进行本地知识库问答。

此前公开课中，我们已经详细讨论了DeepSeek R1从原版模型到蒸馏模型的各系列模型本地安装部署方法，以及借助ollama、vLLM、LMDeploy等主流推理框架进行调用等方法，详情见：<https://www.bilibili.com/video/BV19kFoe6Ef7/>


【保姆级】DeepSeek R1本地部署与调用指南 | transformer、Ollama、vLLM、LMDeploy、SG...
1.1万 49 2025-02-01 14:55:12 未经授权，禁止转载



本节公开课，我们继续探讨如何借助DeepSeek R1进行本地知识库问答。


关于本地知识库问答，目前有非常多实现方法，主流的本地知识库问答开源框架如下：

- 【个人】多端&多模型聊天框架：ChatBox
 - 项目展示：





- GitHub地址：<https://github.com/Bin-Huang/chatbox>

- 【个人】轻量级便捷RAG推理框架：AnythingLLM
 - 项目展示：




- 项目官网：<https://anythingllm.com/>
- 【企业级】RAG&GraphRAG知识库对话框架：kotaemon
 - 项目展示：




◦ Github主页地址<https://github.com/Cinnamon/kotaemon>



• 【企业级】RAG&Agent多功能综合前端框架：Open-WebUI

◦ 项目展示：






- GitHub项目地址：<https://github.com/open-webui/open-webui>
- 【企业级】多模态交互框架：lobe-chat
 - 项目展示：



- GitHub项目地址：<https://github.com/lobehub/lobe-chat>

本节公开课将以AnythingLLM为例介绍DeepSeek R1本地知识库问答实现全流程，而对于更加复杂的框架，如Open-WebUI、Kotaemon等，我们提供了完整的完整的参考课件资料，与本节公开课课件、代码、软件等保存在同一网盘内：



我的网盘 > 九天老师大模型系列公开课课件 > **DeepSeek R1私有知识库问答** > Open-WebUI&kotaemon课件

全部文件

已全部加载，共2个

☐	文件名	大小	类型	修改时间
☒	Kotaemon快速入门实战.ipynb	36.10KB	ipynb文件	2025.02.02 20:46
☒	二次开发Open WebUI项目构建专属...	63.64KB	ipynb文件	2025.02.02 20:46

本次公开课全部课件已同步至赋范大模型技术社区，下图扫码加入大模型社区即可领取哦：

我的网盘 > 九天老师大模型系列公开课课件 > DeepSeek R1私有知识库问答

全部文件

已全部加载，共5个

☐	文件名	大小	类型	修改时间
☒	课件	-	文件夹	2025.02.02 20:47
☒	Open-WebUI&kotaemon课件	-	文件夹	2025.02.02 20:46
☒	AnythingLLM安装文件	-	文件夹	2025.02.02 18:45
☒	Ollama安装文件	-	文件夹	2025.02.02 18:44
☒	DepeSeek R1 Distill 14B模型权重	-	文件夹	2025.02.02 18:43

加入大模型技术交流社区


免费!

5000+ 大模型爱好者聚集地

- ✓ AI 大模型社群
AI 大模型技术爱好者共同探讨! 氛围超赞
- ✓ 独家大模型学习资料
及时更新 AI 技术文档! AI 路上不掉队
- ✓ 500+ 课程视频
超长时间自研 AI 技术免费课! 零基础入门
- ✓ 群内技术答疑
AI 行业头部技术人员为你在线答疑

一起拥抱 AI 未来

扫描二维码 领加入社区资格



扫这里

二、Ollama+DeepSeek R1 Distill模型本地部署

- 模型选择与硬件配置说明


本节公开课以Windows系统为例进行演示, MacOS、Linux系统实现方式也类似。同时, 公开课重点介绍完全本地部署实现方案, 并采用DeepSeek R1蒸馏模型进行演示, 若硬件条件允许, 也可考虑部署原版DeepSeek R1模型。各模型运行所需显存如下:

DeepSeek R1模型组	模型推理性能	半精度运行所需显存	全精度运行所需显存
DeepSeek-R1-1.5B (Distill)	GPT4o级	1.1G	4G
DeepSeek-R1-7B (Distill)	超越GPT4o	4.7G	14G
DeepSeek-R1-8B (Distill)	超越GPT4o	4.9G	14G
DeepSeek-R1-14B (Distill)	超越GPT4o	9G	24G
DeepSeek-R1-32B (Distill)	o1 mini级	20G	55G
DeepSeek-R1-70B (Distill)	o1 mini级	43G	120G
DeepSeek-R1-671B	o1级	404G	1000G


而关于如何使用DeepSeek R1在线API实现相关功能, 详见Part 4部分内容介绍。

- 模型本地调度框架选取

同其他主流大模型对话Web框架类似, AnythingLLM同时支持调用在线模型API、或本地模型进行推理, 并且AnythingLLM本身是一款集成度非常高的聊天框架, 我们只需要借助可视化页面手动点击选择在线模型API或者本地推理框架即可, 例如一些主流API厂商:




或者一些主流的本地推理框架。




本节公开课我们将以Ollama为例进行演示。

Step 1.安装ollama

首先需要先安装ollama地址，下载地址：<https://ollama.com/>





选择对应的操作系统进行安装即可：




Ollama下载存在网络限制，对应Windows、MacOS软件安装包开在课件网盘中领取：



下载后即可开始安装：



而当Ollama安装结束后，会自动在后台开启Ollama进程，Windows系统下可以按住Win+r键，输入cmd开启命令行，并在命令行中查看Ollama运行情况：



例如, 输入 `tasklist | findstr ollama` 查看Ollama进程是否存在

```
管理员: C:\WINDOWS\system...
Microsoft Windows [版本 10.0.22631.4602]
(c) Microsoft Corporation. 保留所有权利。

C:\Users\Administrator>tasklist | findstr ollama
ollama.exe           38316 Console             4      21,600 K


C:\Users\Administrator>
```

如此则说明Ollama已启动。若未启动, 可输入 `ollama start` 启动Ollama。

Step 2. 下载DeepSeek R1模型

接下来即可进一步下载DeepSeek R1模型了, 这里我们可以直接使用 `ollama pull` 命令自动下载与注册, 也可以手动下载模型的GGUF文件, 然后手动完成Ollama模型注册, 再进行调用。

这里我们考虑使用 `ollama pull` 方法进行模型权重下载, 而若网络条件不允许, 也可以参考我的另一个视频: 《DeepSeek R1本地部署流程详解》<https://www.bilibili.com/video/BV19kFoe6Ef7/>, 从魔搭社区上手动下载模型GGUF权重, 并完成Ollama注册与调用。



首先输入 `ollama list` 查看当前模型列表：

```
管理员: C:\WINDOWS\system32\cmd.exe
Microsoft Windows [版本 10.0.22631.4602]
(c) Microsoft Corporation。保留所有权利。

C:\Users\Administrator>ollama list
NAME        ID          SIZE      MODIFIED
C:\Users\Administrator>
```

然后回到ollama deepseek r1模型列表，查看模型组情况：<https://ollama.com/library/deepseek-r1>

 [Discord](#) [GitHub](#) [Models](#)

[Sign in](#) [Download](#)

deepseek-r1

DeepSeek's first-generation of reasoning models with comparable performance to OpenAI-o1, including six dense models distilled from DeepSeek-R1 based on Llama and Qwen.

[1.5b](#) [7b](#) [8b](#) [14b](#) [32b](#) [70b](#) [671b](#)

[6.2M Pulls](#) [Updated 11 days ago](#)

7b

28 Tags

ollama run deepseek-r1

Updated 12 days ago	0a8c26691023 · 4.7GB
model	arch qwen2 · parameters 7.62B · quantization Q4_K_M · 4.7GB
params	{ "stop": ["< begin_of_sentence >", "< end_of_sentence >"] }
template	{{- if .System }}{{ .System }}{{ end }} {{- range \$i, \$_ := .Mes...
license	MIT License Copyright (c) 2023 DeepSeek Permission is hereby gra... · 1.1kB

[Readme](#)

deepseek-r1

DeepSeek's first-generation of reasoning models with comparable performance to OpenAI-o1, including six dense models distilled from DeepSeek-R1 based on Llama and Qwen.

[1.5b](#) [7b](#) [8b](#) [14b](#) [32b](#) [70b](#) [671b](#)

[6.2M Pulls](#) [Updated 11 days ago](#)

7b

28 Tags

ollama run deepseek-r1

Updated 12 days ago	0a8c26691023 · 4.7GB
model	arch qwen2 · parameters 7.62B · quantization Q4_K_M · 4.7GB
params	{ "stop": ["< begin_of_sentence >", "< end_of_sentence >"] }
template	{{- if .System }}{{ .System }}{{ end }} {{- range \$i, \$_ := .Mes...
license	MIT License Copyright (c) 2023 DeepSeek Permission is hereby gra... · 1.1kB

7b

28 Tags

ollama run deepseek-r1

1.5b

1.1GB

7b

4.7GB

8b

4.9GB

14b

9.0GB

32b

20GB

70b

43GB

671b

404GB

View all

[Readme](#)

其中不同尺寸模型运行所需占用显存大小如上所示。需要注意的是，ollama只支持运行Q4_K_M模型，相当于是4bit量化后的模型，因此每个模型运行所需占用显存并不大。

接下来使用如下命令下载模型，这里以14b模型为例，下载其他模型的话只需要修改模型名称即可，例如修改为 `deepseek-r1:7b`，则代表下载7b模型：

```
ollama pull deepseek-r1:14b
```

```
管理员: C:\WINDOWS\system...
Microsoft Windows [版本 10.0.22631.4602]
(c) Microsoft Corporation。保留所有权利。

C:\Users\Administrator>ollama list
NAME      ID      SIZE      MODIFIED

C:\Users\Administrator>ollama pull deepseek-r1:14b
pulling manifest
pulling 6e9f90f02bb3... 19% ██████████ | 1.7 GB/9.0 GB 17 MB/s 6m45s
```

稍等片刻即可完成下载。下载完成后即可使用 `ollama list` 命令查看当前模型是否完成下载与注册：

```
Microsoft Windows [版本 10.0.22631.4602]
(c) Microsoft Corporation。保留所有权利。

C:\Users\Administrator>ollama list
NAME      ID      SIZE      MODIFIED

C:\Users\Administrator>ollama pull deepseek-r1:14b
pulling manifest
pulling 6e9f90f02bb3... 100% ██████████ 9.0 GB
pulling 369ca498f347... 100% ██████████ 387 B
pulling 6e4c38e1172f... 100% ██████████ 1.1 KB
pulling f4d24e9138dd... 100% ██████████ 148 B
pulling 3c24b0c80794... 100% ██████████ 488 B
verifying sha256 digest
writing manifest
success


C:\Users\Administrator>ollama list
NAME      ID      SIZE      MODIFIED
deepseek-r1:14b  ea35dfe18182  9.0 GB  7 minutes ago

C:\Users\Administrator>
```

接下来即可调用DeepSeek R1 Distill 14B模型进行本地知识库问答了。

三、AnythingLLM安装与使用


AnythingLLM是一款集成度非常高、且功能非常稳定的大模型对话前端产品，虽无法进行二次开发，但功能实现方面非常便捷，可以直接从AnythingLLM官网进行下载：<https://anythingllm.com/>



选择对应的操作系统版本下载安装即可开始安装：



安装完成后，会自动启动AnythingLLM，并进入设置页面



点击Get started，则进入到选择LLM页面：

LLM Preference

AnythingLLM can work with many LLM providers. This will be the service which handles chatting.

 Google ChatGPT and most open-source models.

**NVIDIA NIM**
Run full parameter LLMs directly on your NVIDIA RTX GPU using NVIDIA NIM.

**HuggingFace**
Access 150,000+ open-source LLMs and the world's AI community

**Ollama**
Run LLMs locally on your own machine.

**Novita AI**
Reliable, Scalable, and Cost-Effective for LLMs from Novita AI

**LM Studio**

Ollama Model	Max Tokens
deepseek-r1:14b Choose the Ollama model you want to use for your conversations.	4096 Maximum number of tokens for context and response.

Show advanced settings ▾



Provider endpoint discovered automatically.



这里我们选择借助Ollama来调用本地的14B模型。这里需要注意的是，AnythingLLM会自动检测Ollama进程是否存在（也就是Ollama是否启动），以及现在Ollama中已经注册了哪些模型。因此在进入到上面这个设置也面前，需要确保Ollama已经启动，并且已完成了相关模型注册。选择好14B模型之后即可点击进入下一步：

Data Handling & Privacy

We are committed to transparency and control when it comes to your personal data.

对话模型

LLM Selection



Ollama

- Your model and chats are only accessible on the machine running Ollama models

Embedding模型

Embedding Preference



AnythingLLM Embedder

- Your document text is embedded privately on this instance of AnythingLLM

词向量数据库

Vector Database



LanceDB


- Your vectors and document text are stored privately on this instance of AnythingLLM

These settings can be reconfigured at any time in the settings.

该页面是进行模型配置说明，当前的模型配置是：

- 对话模型：负责完成对话任务，由Ollama调度DeepSeek R1 Distill 14B来完成对话；
- Embedding模型：负责进行词向量化模型，由AnythingLLM官方提供；
- 词向量数据库：用于存储词向量化之后的对象，默认为LancelotDB；

对于任何一个本地知识库问答的过程，都需要经历文本切割、词向量化、词向量存储、词向量检索与问答几个基本环节，因此至少需要Chat模型、Embedding模型以及词向量数据库作为基础组件。对于RAG的基本原理回顾如下：



在浏览了当前模型配置后，接下来即进入到AnythingLLM注册页面，这里可以直接跳过：

v1.7.3

Welcome to AnythingLLM

Help us make AnythingLLM built for your needs. Optional.

What's your email?

you@gmail.com

What will you use AnythingLLM for?

☐ For work

☐ For my personal use

☐ Other

Any comments for the team? (Optional)

If you have any questions or comments right now, you can leave them here and we will get back to you. You can also email team@mintplexlabs.com

Skip Survey

点击跳过即可

然后需要创建一个workspace，相当于是ChatGPT或者其他开发项目的一个Project，用于对对话进行分类：

v1.7.3

Create your first workspace

Create your first workspace and get started with AnythingLLM.




工作区名称


RAG Test

→


当我们进入到如下页面，则说明安装成功：



接下来即可尝试进行对话了。AnythingLLM对于DeepSeek R1系列模型的支持是非常友好的，甚至会区分思考过程和回答过程：



并且支持多轮对话：




四、借助AnythingLLM进行本地知识库问答

AnythingLLM是一款集成度非常高、且运行稳定的RAG+前端对话框，我们可以非常便捷的为每次对话设置知识库。主要方法有以下两种：


- 在单次问答中设置背景文本

例如，我们可以直接在对话框下方点击回形针按钮，即可上传文本并进行对话，整个过程类似ChatGPT的功能实现：


注：这里所谓上传文本，并不是把文本上传到远程服务器，而是将文本进行切分、Embedding后上传到本地的LanceDB词向量数据库中。整个过程全部都在本地完成。




上传文本：



等待文本切分与词向量化过程



然后即可开始问答：




此时迷哦行问答即会根据文档进行回答。

- 统一知识库管理


此外，若想让整个文本长期存在于当前对话中，则需要借助AnythingLLM的知识库管理功能。下面这个icon就是知识库管理图标（UI需优化）：




点击后即可进入到如下页面：




这里我们额外上传一份DeepSeek V3技术报告，该报告的内容超出了当前模型只是范畴，适合进行本地文档问答测试：




上传后即可在当前文件夹中看到该文件，这里点击Move to Workspace，即可将其列举为备选问答文档：




当Move to workspace后，在右侧即可看到这篇文档，然后点击Save and Embed，即可开始进行文档切分和词向量化过程：




需要稍等片刻：




完成后，再点击图钉按钮，即可将这篇文档设置为当前对话的背景文档：




然后点击got it



然后即可提问：



能够看出, 此时回答结果就会根据当前文档进行回答, 细节丰满回答流畅。而若不绑定知识库, 则模型并不知道DeepSeek V3模型:




至此, 即完成了DeepSeek R1 Distill 14B模型的本地知识库问答全流程。


五、DeepSeek R1 API接入AnythingLLM进行本地知识库问答

最后, 让我们来看下如何借助DeepSeek R1 API+AnythingLLM来进行本地知识库问答。


首先, 新建一个工作区, 并命名为RAG Test2




然后点击设置按钮：




设置页面，我们可以灵活设置当前工作区域的名称（或者删除工作区）




或者修改默认模型，以及system message（系统默认提示）：




以及进行词向量数据库设置等。




这里我们需要在聊天设置中修改模型为DeepSeek R1 API，先点击聊天设置，然后选择模型：




然后在模型提供商中选择DeepSeek：




然后在弹出的页面输入API-KEY




输入完API-Key后，即可选择对话模型，deepseek-chat就是DeepSeek V3，而deepseek-reasoner则是DeepSeek R1。这里我们选择deepseek-reasoner：



然后点击Save，即可返回设置页面：



然后翻到最下面点击Update workspace，即可完成设置：



然后点击左侧聊天栏，选择default会话即可开始聊天了：



如此即可完成对话，而若要进一步设置知识库，可参考Part 4中部分内容，无论是调用在线模型API，还是调用本地模型，知识库设置流程都完全一样。